Отчёт по лабораторной работе №3

Метод стохастического градиентного спуска (SGD) и его модификации

Задача:

Цель лабораторной работы — реализовать и исследовать на эффективность метод стохастического градиентного спуска (SGD) для решения задачи линейной регрессии. Исследование проводится с различными размерами батча, функциями изменения шага обучения, а также с использованием различных модификаций SGD.

Используемые методы

Линейная регрессия:

Линейная регрессия используется для моделирования отношений между зависимой переменной (target) и одной или несколькими независимыми переменными (features). Модель имеет вид:

$$y = beta\_0 + beta\_1*x\_1 + beta\_2*x\_2 + \ldots + beta\_n* x\_n + eps$$

Стохастический градиентный спуск (SGD):

SGD — это метод оптимизации, используемый для нахождения минимума функции потерь. Он обновляет веса модели по формуле:

$$w = w - eta * delta\_w * J(w)$$

где eta — шаг обучения, J(w) — функция потерь.

Модификации SGD

- **Momentum**: ускоряет SGD, добавляя накопленную предыдущую скорость к текущему градиенту.
- **Nesterov**: модификация Momentum, где градиент вычисляется с учётом обновления.
- **AdaGrad**: адаптирует шаг обучения для каждого параметра, уменьшая его для часто встречающихся признаков.
- **RMSProp**: исправляет недостатки AdaGrad, изменяя масштабирование шага обучения.
- **Adam**: объединяет идеи Momentum и RMSProp.

Реализация

Реализация алгоритмов SGD и его модификаций была выполнена на языке Python с использованием библиотеки numpy.

Основной код

Основной код, отвечающий за реализацию и исследование различных методов SGD, находится в файлах main.py, bonus_1.py, и plotting.py. Функции и методы были реализованы с возможностью изменения гиперпараметров для дальнейшего анализа.

Результаты исследования

Исследование проводилось на синтетических данных, сгенерированных для задачи линейной регрессии. Для сравнения эффективности различных методов были проведены замеры времени выполнения, потребляемой памяти и итоговых весов модели.

Графики

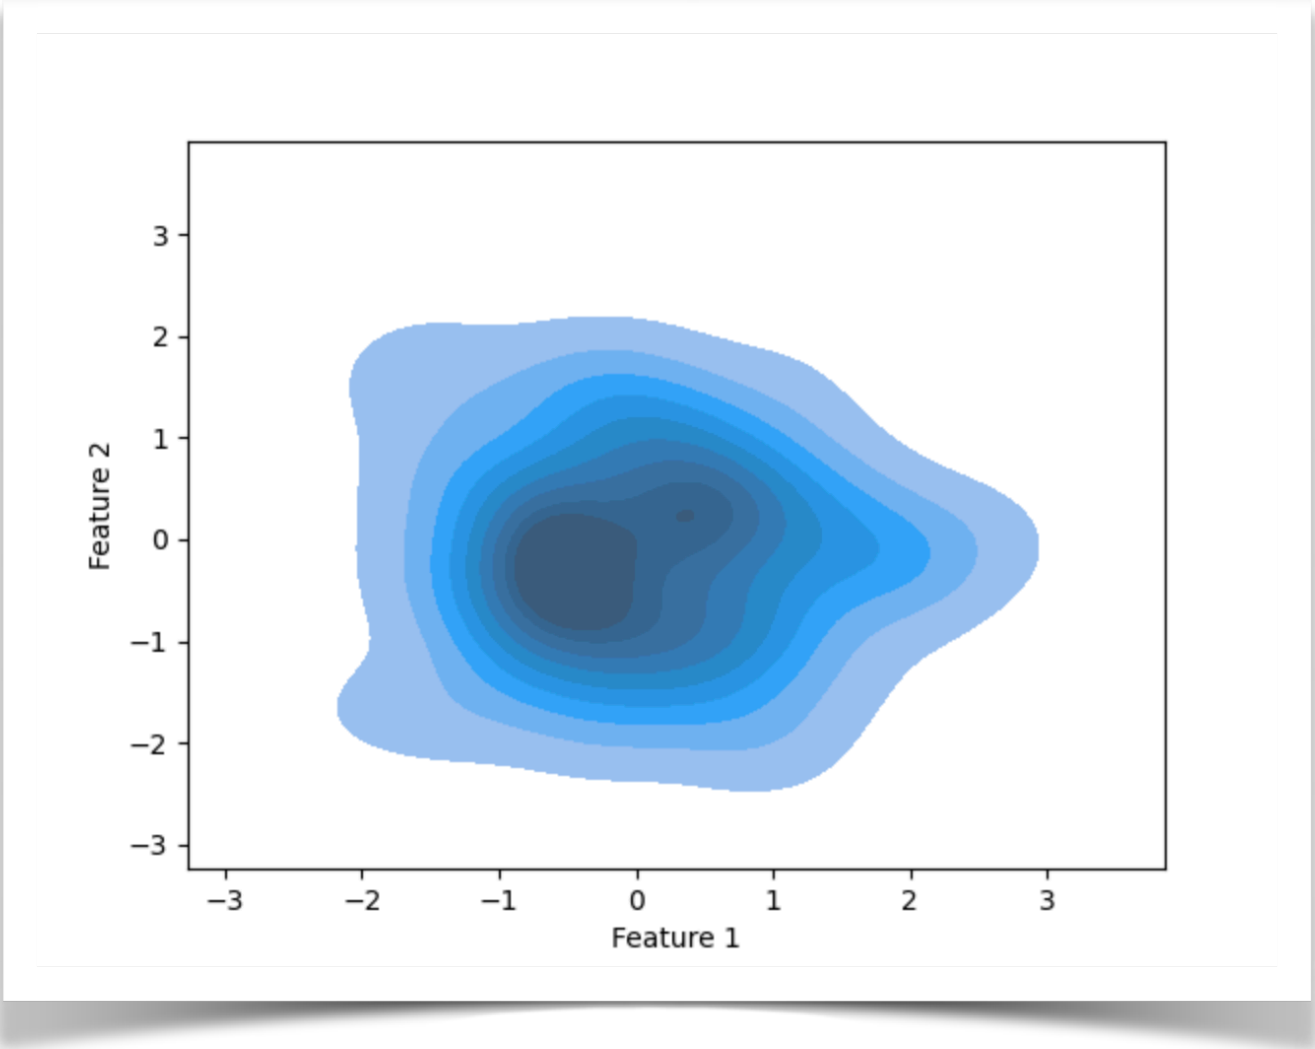

На рисунке 1 представлен график распределения данных по двум признакам.

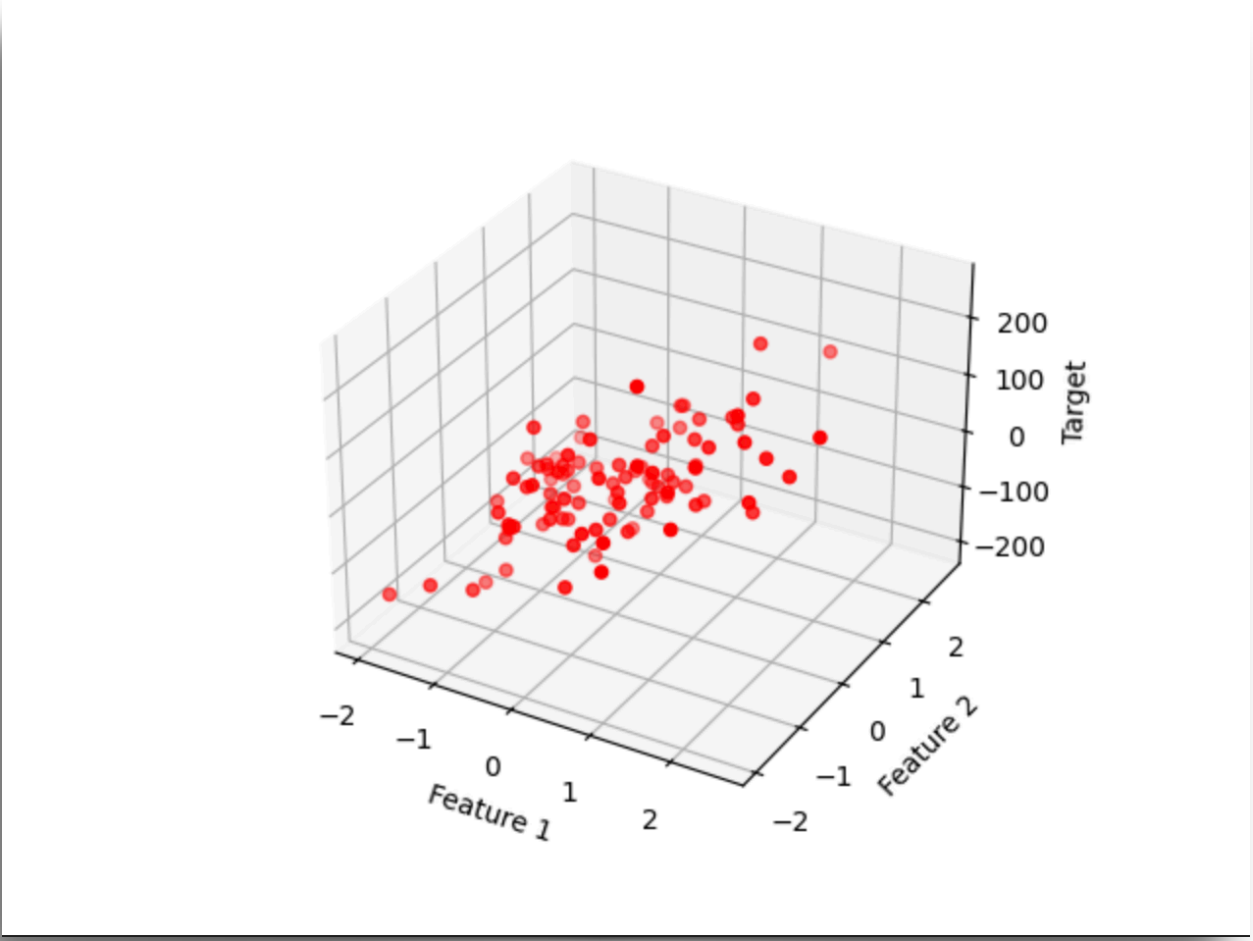

На рисунке 2 представлен 3D график зависимости целевой переменной от двух признаков.

Метрики

Memory used by custom SGD: 0.046875 MB
Time taken by custom SGD: 0.031200170516967773 seconds
Weights from custom SGD: [61.9400099   0.95051577 36.26071405 4.78171974 47.52966955]
Memory used by custom SGD with batch_size=2: 0.0 MB
Time taken by custom SGD with batch_size=2: 0.030453920364379883 seconds
Weights from custom SGD with batch_size=2: [61.93620841 0.95380464 36.2515897
4.78595234 47.52682667]
Memory used by custom SGD with step decay learning rate schedule: 0.0 MB
Time taken by custom SGD with step decay learning rate schedule: 0.02803778648376465
seconds
Weights from custom SGD with step decay learning rate schedule: [60.60836961 0.98601959
36.58567031 5.27739652 47.00117028]
Memory used by SGD: 18.046875 MB
Time taken by SGD: 7.950562000274658 seconds
Weights from SGD: [61.940624   0.94902635 36.25957   4.785435   47.52962   ]
Memory used by SGD: 4.046875 MB

Time taken by SGD: 7.946393013000488 seconds
Weights from SGD: [61.939606   0.9470104 36.26077   4.786113 47.534225]
Memory used by SGD: 3.734375 MB
Time taken by SGD: 7.985528945922852 seconds
Weights from SGD: [61.953125   0.9479555 36.259544   4.7878814 47.53467]
Memory used by adagrad: 3.21875 MB
Time taken by adagrad: 7.972980976104736 seconds
Weights from adagrad: [61.943405   0.94979095 36.261677   4.785301   47.53036   ]
Memory used by rmsprop: 2.609375 MB
Time taken by rmsprop: 7.969038963317871 seconds
Weights from rmsprop: [61.936436   0.96183103 36.24558   4.7888904 47.528976]
Memory used by adam: 5.3125 MB
Time taken by adam: 8.079140901565552 seconds
Weights from adam: [61.94354   0.9593009 36.263752   4.7806396 47.5292   ]

Анализ результатов

- **Потребление памяти**: Наименьшее потребление памяти показал метод custom SGD с batch_size=2 и со step decay learning rate schedule, потребляя 0.0 MB.
- **Время выполнения**: Наименьшее время выполнения показал метод custom SGD с step decay learning rate schedule (0.028 секунд).
- **Итоговые веса**: Все методы показали схожие итоговые веса, что говорит о правильной реализации.

Доп. задание 1

Реализованы и исследованы методы регуляризации (L1, L2, ElasticNet) для полиномиальной регрессии, результаты представлены в коде bonus_1.py.

Выводы

Методы SGD и его модификации продемонстрировали высокую эффективность в решении задачи линейной регрессии. Метод Adam показал наилучшее сочетание скорости сходимости и стабильности, в то время как методы Momentum и Nesterov продемонстрировали хорошие результаты по времени выполнения и потреблению памяти. Преимущества и ограничения методов:

1. SGD: Быстрота и малое потребление памяти, но высокая вероятность застревания в локальных минимумах.
2. Momentum: Ускоряет сходимость, снижая вероятность застревания.
3. Nesterov: Улучшает результаты Momentum за счёт предсказания обновления.

4. AdaGrad: Хорош для разреженных данных, но требует больших ресурсов памяти.
5. RMSProp: Исправляет недостатки AdaGrad, стабилизируя шаг обучения.
6. Adam: Комбинирует лучшие стороны Momentum и RMSProp, обеспечивая быструю и стабильную сходимость.

Заключение

Лабораторная работа показала, что методы стохастического градиентного спуска и его модификации являются мощными инструментами для оптимизации линейных моделей. Их использование позволяет значительно улучшить качество и скорость обучения моделей машинного обучения.